



刘宇广

AI 评测 / 测试开发

📅 2027 届全职秋招，可提前实习

✉ lyg3044@qq.com

☎ 18771478399

🌐 <https://ygrowly.github.io/>

给不确定的模型输出建可复现的验收标准：把「哪版更好」变成能重跑、能归因、能卡住发布的确定性证据——评测集与防污染、独立 Oracle 裁决、回归门禁与反例回流。

教育经历

南华大学
数据科学与大数据技术 · 本科
实习经历

2023/09 - 2027/06

KINGSOFT 金山 · AI 开发实习生

2026/05 - 至今

EnergyOps Agent · 园区能耗智能运营平台（独立设计与实现，Mentor 把关业务方向）
面向园区行政与财务：把每月手工对账、真告警被噪音淹没的能耗运营，改为第三方 604 台水电表参差读数 → 分层建模与异常治理 → 受控 Agent 入口的自动化链路，产出可交付财务的**月度结算单**（带计算说明、规则版本与差异检查）。
■ 结算设**三道质量门**：事实源门→预演门（分摊守恒校验）→责任门（行政确认 + 财务核验），任一失败阻断正式账单生成，分摊守恒率 100%；**92 项单元 + 30 项回归测试**把关核心链路，通过率 98.4%
■ 把查询、设备、规则、告警、导出与结算封装为 **30 个 MCP 工具**与 6 类 Capability Bundle，实施 **R0/R1/R2 操作风险分级**与 Before/After Tool 校验链，固定 72 条任务集（同模型同权限）完成率 83.3%→95.8%；**80 条越权用例**（跨租户 / 越权限 / 越范围）**拦截率 100%**
■ 误报治理「**异常候选 ≠ 业务告警**」**三层分离**：自适应基线输出异常候选，历史 dry-run 准入与告警指纹去重守住通知门槛，告警量降低 43%、平均研判时间 18min→6min
■ 「**三账一体**」**核心设计**：独立构建 raw→interval→hourly→daily **四层能耗数据模型**，定义 7 类质量状态与可信白名单，把参差读数整理为可信用能账、异常账与结算账，可信聚合完整率（有效区间→应产生区间）96.8%→99.7%

慧泽致远 · AI 应用开发实习生

2025/10 - 2026/03

数驭穹图 · 企业 AI 数据分析与协作平台（初创团队核心开发：Data Agent 链路、安全边界与评测模块）
面向中小企业业务人员：把「找数据同学写 SQL、等排期」的取数方式，改为统一接入数据库、飞书、协同表格等 6 类数据源的自然语言可信分析，产出有**来源、有口径、可验证、可编辑共享的分析结果**，不是一段 SQL。
■ 「**SQL 能执行 ≠ 业务答案正确**」：设计 Data Agent **六阶段可归因链路**（意图路由→Schema 检索→NL2SemQL→SQL 生成→安全校验→执行）与限次自愈，单条 Bad Case 定位 30min→8min，150 条评测集「可执行且口径正确」的查询占比 78%→91%（含人工复核判定）
■ 构建 **5 层查询安全边界**（租户权限→受治理 Tool 注册→Tool Call Schema/Validator 校验→只读 SQL AST 审查→输出字段脱敏），300 条正常与对抗请求中危险语句拦截率 100%、正常查询误拦率 2.7%
■ **断言式口径校验：健康度评分与一票否决**——核心指标缺少业务定义即暂停该域自动问数；Schema/DDI 变更自动降级资产可信度，过期语义不能冒充当前口径；结果绑定 call_id / query_fingerprint / result_hash 三重证据，100 条抽检复现一致率 100%
■ 分析负载与客户生产库物理隔离：文件、协同表格与同步数据以 Parquet 副本交由 DuckDB 本地计算，强实时查询走只读受限连接（EXPLAIN 成本预估、慢查询熔断降级）；大结果外置为 **Artifact**，单次分析上下文 Token 18.4K→3.6K（↓80.4%）
■ 沉淀出海电商、医美、教育 **3 套 Domain Pack**（65 个核心指标 + 120 个术语别名 + 表关联约束），结合领域路由与混合检索，Top-K Schema 召回率 81%→95%

项目经历

RuleArena · 业务 Agent 上线前的执行门禁平台

2026/08 - 至今

个人项目 · 独立设计与实现
面向**业务 Agent 上线前的执行门禁**：Agent 负责做事，系统负责证明它没做错——工具返回 ACK 不等于业务成功；信任由 Agent 之外的三层给出：类型化工具契约、运行时门禁、独立 Oracle（确定性裁决，不采信 Agent 自述）。
■ 建立 **21 + 17 双评测集**（hidden 物理隔离、Runtime 不可读）做四基线归一化预算消融：dev 集 Multi-strategy 5/14 高于确定性 BFS 2/14；但 hidden 重复 3 次暴露 **pass@3 = 8/14 而 pass^3 = 1/14**——单次成绩掩盖搜索不可复现，Release Gate 据此**如实拒绝放行**（57% < 75% 门槛）；机制层误报 0 / 泄漏 0 / 稳定重放 42/42
■ 「**候选风险 ≠ 确认漏洞**」：Agent 提议只算候选，经 Reference Simulator 快速探索→干净 Commerce Sandbox（幂等键 + ActionReceipt + 只追加事件）真实 HTTP 重放→独立 Oracle 依据资金守恒、状态生命周期与幂等不变量裁决方可确认；Agent 不能触达 Ground Truth
■ **门禁实测（同一份 Agent 跑两次，15 张工单 × 3 次重复）**：裸跑组 6 张工单重复退款、多退 **¥1920**、终态正确率 60%；加门禁后**重复退款 0 笔**、终态正确率 **100%**、误拦 0，且更省——少发 30 次工具调用、平均耗时低 0.3s
■ **缺陷定界（工程 bug vs 效果缺陷）**：执行中打出并修正四个真实缺陷——工具层把沙箱「业务拒绝」（HTTP 200 + status: REJECTED）读成成功、504 未走恢复路径、同幂等键重放被当成新写入、门禁理由码泄给 Agent；修完补回归测试后重跑出上述数字
■ 确认违规经删除式 **Delta Debugging** 压缩为 1-minimal 反例并绑定证据链（请求序列 + 回执 + 事件 + 状态 Diff + 违反的不变量），修复版本自动重放历史反例，反例沉淀进回归套件；显式 FSM 支持 Checkpoint 恢复与 **ACTION_UNKNOWN** 超时语义

专业技能

评测与质量工程：评测集设计与防污染（hidden 物理隔离、Ground Truth 隔离）、pass^k 重复性度量、确定性 Oracle 裁决与模型自评的取舍、回归门禁与发布卡口、Bad Case 压缩与反例回流、误报 / 泄漏度量、故障定界（工程 vs 效果）、越权与提示注入对抗测试
Agent 架构与工程化：Function Calling、MCP 工具封装、Capability Bundle 路由、Hook 链治理（Before/After Tool）、任务状态与进度推送；Prompt Engineering、结构化输出、上下文压缩与 Artifact 外置；RAG / Schema 混合检索；操作风险分级（R0/R1/R2）、HITL 确认、证据契约校验、确定性 Oracle 裁决与发布门禁
工程交付与 AI Coding：Git、pytest、CI/CD、Docker Compose、Nginx；分层评测体系、归一化预算消融、Bad Case 回归集；Claude Code / Codex（Skills / Hooks / AGENTS.md 仓库级实践）；CET-6
后端开发与数据工程：Python、FastAPI、SQLAlchemy、Pydantic；REST / SSE、异步任务编排；PostgreSQL、MySQL、Redis、DuckDB、Parquet；数据分层建模、湖仓查询路由、指标口径治理；幂等控制、状态机约束、失败语义分级