



# 刘宇广

AI 评测 / 测试开发

📅 2027 届全职秋招，可提前实习

✉ lyg3044@qq.com

☎ 18771478399

🌐 <https://ygrowly.github.io/>

给不确定的模型输出建可复现的验收标准：把「哪版更好」变成能重跑、能归因、能卡住发布的确定性证据——评测集与防污染、独立 Oracle 裁决、回归门禁与反例回流。

## 教育经历

南华大学

数据科学与大数据技术 · 本科

2023/09 - 2027/06

## 实习经历

KINGSOFT 金山 · AI 开发实习生

2026/05 - 至今

EnergyOps Agent · 园区能耗智能运营平台（独立设计与实现，Mentor 把关业务方向）

面向园区行政与财务团队，对接第三方能耗平台约 604 台水电表累计读数，经分层建模、异常治理与受控 Agent 入口，最终产出可交付财务的月度结算单（带计算说明、规则版本与差异检查）。

- 结算设三道质量门：事实源门→预演门（分摊守恒校验）→责任门（行政确认 + 财务核验），任一失败阻断正式账单生成，分摊守恒率 100%；92 项单元 + 30 项回归测试把关核心链路，通过率 98.4%
- 把查询、设备、规则、告警、导出与结算封装为 30 个 MCP 工具与 6 类 Capability Bundle，实施 R0/R1/R2 操作风险分级与 Before/After Tool 校验链，固定 72 条任务集（同模型同权限）完成率 83.3%→95.8%；80 条越权用例（跨租户 / 越权限 / 越范围）拦截率 100%
- 误报治理「异常候选 ≠ 业务告警」三层分离：自适应基线输出异常候选，历史 dry-run 准入与告警指纹去重守住通知门槛，告警量降低 43%、平均研判时间 18min→6min
- 「三账一体」核心设计：独立构建 raw→interval→hourly→daily 四层能耗数据模型，定义 7 类质量状态与可信白名单，把参差读数整理为可信用能账、异常账与结算账，可信聚合完整率 96.8%→99.7%

慧泽致远 · AI 应用开发实习生

2025/10 - 2026/03

数驭穹图 · 企业 AI 数据分析与协作平台（初创团队核心开发：Data Agent 链路、安全边界与评测模块）

面向中小企业业务人员，统一接入数据库、飞书、协同表格等 6 类数据源，完成自然语言→可信查询→分析解释→结果沉淀；产出的是有来源、有口径、可验证、可编辑共享的分析结果，不是一段 SQL。

- 「SQL 能执行 ≠ 业务答案正确」：设计 Data Agent 六阶段可归因链路（意图路由→Domain Schema 检索→NL2SemQL 语义解析→SQL 生成→安全校验→查询执行）与限次自愈，单条 Bad Case 定位 30min→8min，150 条评测集「可执行且口径正确」的查询占比 78%→91%（含人工复核判定）
- 构建 5 层查询安全边界（租户权限→受治理 Tool 注册→Tool Call Schema/Validator 校验→只读 SQL AST 审查→输出字段脱敏），300 条正常与对抗请求中危险语句拦截率 100%、正常查询误拦率 2.7%
- 断言式口径校验：健康度评分与一票否决——核心指标缺少业务定义即暂停该域自动问数；Schema/DDI 变更自动生成差异任务并降级资产可信度，过期语义不能冒充当前口径
- 分析负载与客户生产库物理隔离：文件、协同表格与同步数据以 Parquet 副本交由 DuckDB 本地计算，强实时查询走只读受限连接（EXPLAIN 成本预估、慢查询熔断降级）；大结果外置为 Artifact，单次分析上下文 Token 18.4K→3.6K（↓80.4%）
- 沉淀出海电商、医美、教育 3 套 Domain Pack（65 个核心指标 + 120 个术语别名 + 表关联约束），结合领域路由与混合检索，Top-K Schema 召回率 81%→95%；分析全程绑定 call\_id / query\_fingerprint / result\_hash 三重证据

## 项目经历

RuleArena · 业务 Agent 上线前的执行门禁平台

2026/08 - 至今

个人项目 · 独立设计与实现

面向业务 Agent 上线前的执行门禁：Agent 负责做事，系统负责证明它没做错——工具返回 ACK 不等于业务成功；信任由 Agent 之外的三层给出：典型化工具契约、运行时门禁、独立 Oracle（确定性裁决，不采信 Agent 自述）。

- 建立 21 + 17 双评测集（hidden 物理隔离、Runtime 不可读）与四基线归一化预算消融（golden-v4 / deepseek-v4.1-flash）：dev 集 Multi-strategy 5/14 高于确定性 BFS 2/14；但 hidden 集重复 3 次暴露 pass@3 = 8/14 而 pass^3 = 1/14——单次成绩掩盖了搜索不可复现。据此 Release Gate 如实拒绝放行（hidden 57% < 75%），机制层误报 0 / 泄漏 0 / 稳定重放 42/42
- 「候选风险 ≠ 确认漏洞」：Agent 提议只算候选，经 Reference Simulator 快速探索→干净 Commerce Sandbox（独立 FastAPI + PostgreSQL，幂等键、ActionReceipt、只追加事件）真实 HTTP 重放→独立 Oracle 依据资金守恒、状态生命周期与幂等不变量裁决方可确认；Agent 不能触达 Ground Truth
- 门禁实测（同一份 Agent 跑两次，15 张工单 × 3 次重复，真实 HTTP + 真实回执/快照/事件）：裸跑组 6 张工单重复退款、合计多退 ¥1920、终态正确率 60%；加运行时门禁后重复退款 0 笔、终态正确率 100%、正常工单误拦 0，且更省——少发 30 次工具调用、平均耗时低 0.3s
- 缺陷定界（工程 bug vs 效果缺陷）：执行中打出并修正四个真实缺陷——工具层把沙箱「业务拒绝」（HTTP 200 + status: REJECTED）读成成功、504 未走恢复路径、同幂等键重放被当成新写入、门禁理由码泄给 Agent；修完补回归测试（6 个测试文件）后重跑出上述数字
- 确认违规经删除式 Delta Debugging 压缩为 1-minimal 反例并绑定证据链（请求序列、回执、事件、状态 Diff、违反的不变量），修复版本自动重放历史反例与正常 Case，反例沉淀为可添加进回归套件的用例；显式 FSM 编排支持 Checkpoint 恢复与 ACTION\_UNKNOWN 超时语义
- 设计自然语言规则→候选 RuleSpec→确定性校验→歧义清单→人工确认→不可变 RuleVersion 的编译链路，仅允许优惠、退款、积分、会员领域固定原语，禁止动态表达式求值，未确认规则不得进入攻击运行

## 专业技能

评测与质量工程：评测集设计与防污染（hidden 物理隔离、Ground Truth 隔离）、pass^k 重复性度量、确定性 Oracle 裁决与模型自评的取舍、回归门禁与发布卡口、Bad Case 压缩与反例回流、误报 / 泄漏度量、故障定界（工程 vs 效果）、越权与提示注入对抗测试

Agent 架构与工程化：Function Calling、MCP 工具封装、Capability Bundle 路由、Hook 链治理（Before/After Tool）、任务状态与进度推送；Prompt Engineering、结构化输出、上下文压缩与 Artifact 外置；RAG / Schema 混合检索；操作风险分级（R0/R1/R2）、HITL 确认、证据契约校验、确定性 Oracle 裁决与发布门禁

工程交付与 AI Coding：Git、pytest、CI/CD、Docker Compose、Nginx；分层评测体系、归一化预算消融、Bad Case 回归集；Claude Code / Codex（Skills / Hooks / AGENTS.md 仓库级实践）；CET-6

后端开发与数据工程：Python、FastAPI、SQLAlchemy、Pydantic；REST / SSE、异步任务编排；PostgreSQL、MySQL、Redis、DuckDB、Parquet；数据分层建模、湖仓查询路由、指标口径治理；幂等控制、状态机约束、失败语义分级